



# TSIGN

Sign language tool





# ¿Por qué TSign?

TSIGN es una herramienta para las personas sordomudas quienes además de su lengua nativa, tienen que aprender otros idiomas, pues el lenguaje de las señas no es universal, sino que cambia dependiendo del idioma en el que las personas quieran comunicarse. Es por esto que esta aplicación ayudará a las instituciones en el proceso de capacitación de una forma interactiva.






# DATASET

## WLASL



21083 vídeos

2000 clases



800 vídeos

10 clases





# PRE PROCESAMIENTO DE LOS VÍDEOS



Debido a que cada clase tiene un promedio de 10 a 12 vídeos se crearon más mediante el uso de métodos como lo son desplazamiento, espejo y cambio en el orden de los canales RGB, de esta forma logrando subir el numero de muestras aproximadamente a 80 por cada clase

# TRATAMIENTO

01

BACKGROUND SUBTRACTION

02

OPTICAL FLOW

03

EDGES WITH OPTICAL  
FLOW

04

BAG OF WORDS

05

EDGES WITH CORNER  
HARRIS

06

CART POLAR



01

## BACKGROUND SUBTRACTION




02

## OPTICAL FLOW




03

## EDGES WITH OPTICAL FLOW



05

## EDGES WITH CORNER HARRIS




04

## BAG OF WORDS



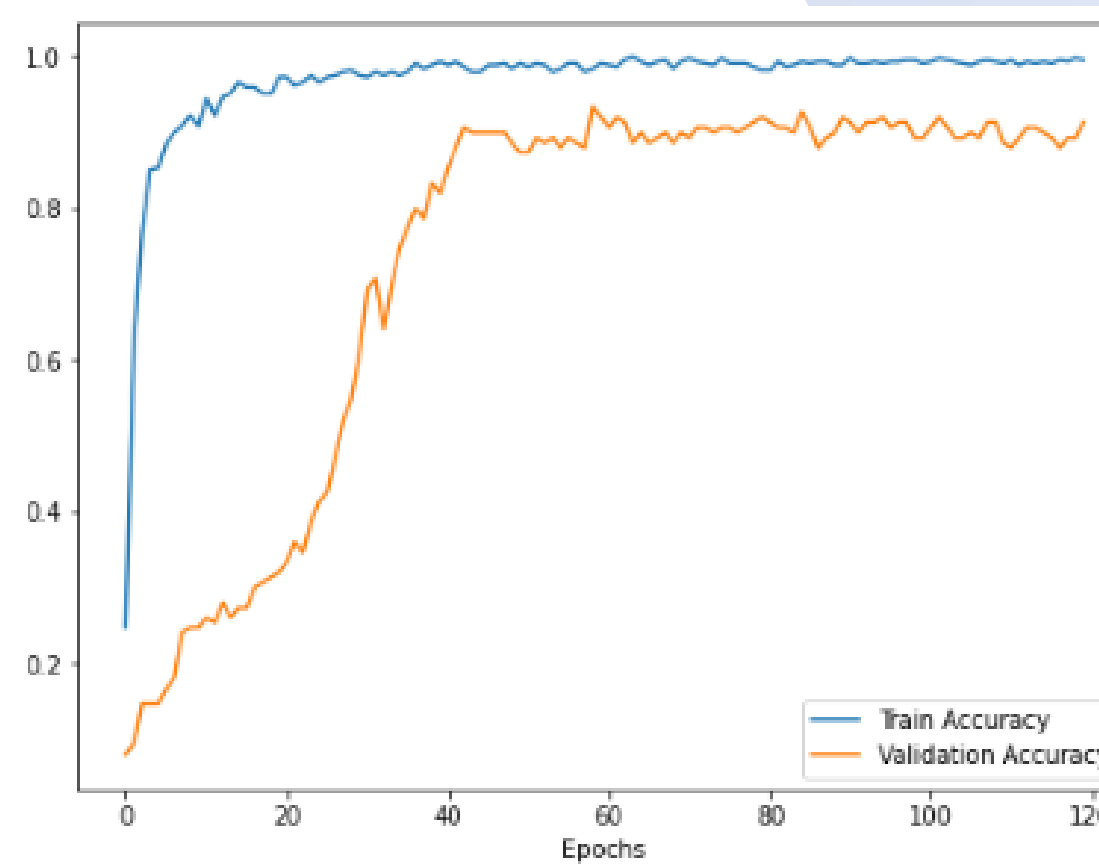
06

## OPTICAL FLOW AND CART POLAR



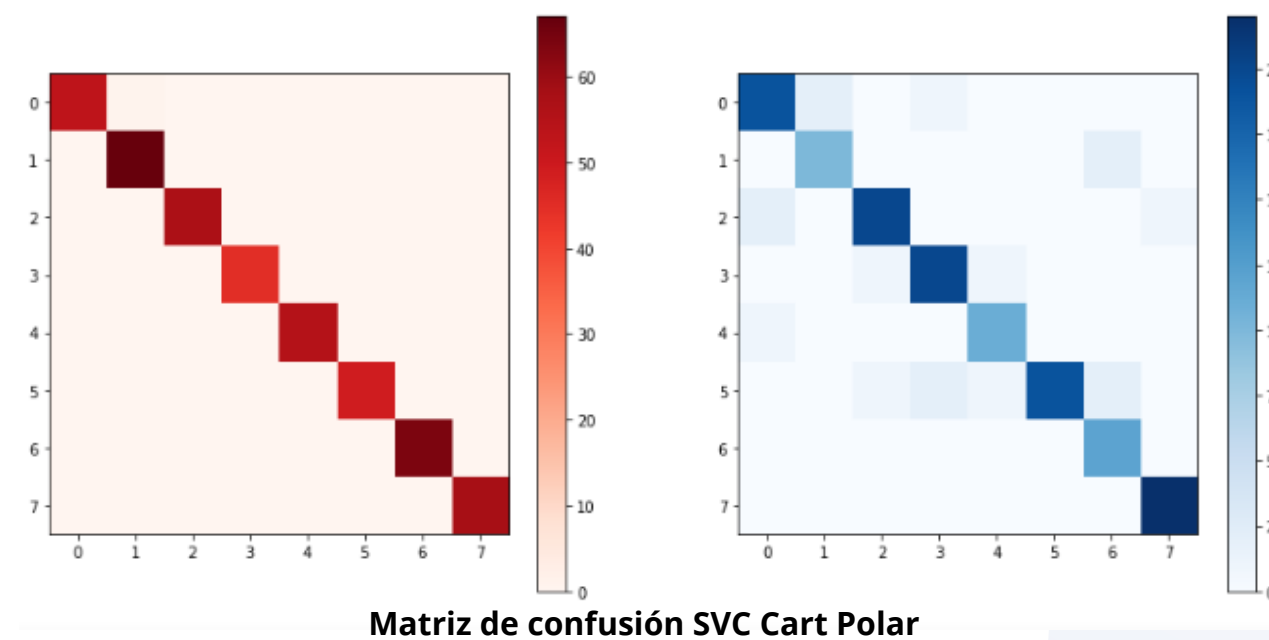

# MEJORES RESULTADOS

Layer (type)	Output Shape	Param #
dense_93 (Dense)	(None, 700)	14700
batch_normalization_40 (Batch Normalization)	(None, 700)	2800
dense_94 (Dense)	(None, 400)	280400
batch_normalization_41 (Batch Normalization)	(None, 400)	1600
dense_95 (Dense)	(None, 300)	120300
batch_normalization_42 (Batch Normalization)	(None, 300)	1200
dense_96 (Dense)	(None, 100)	30100
batch_normalization_43 (Batch Normalization)	(None, 100)	400
dense_97 (Dense)	(None, 8)	808
Total params: 452,308		
Trainable params: 449,308		
Non-trainable params: 3,000		







99% train

91% test



# OTROS RESULTADOS






# OTROS RESULTADOS

Model: "sequential\_15"


Layer (type)	Output Shape	Param #
conv2d_45 (Conv2D)	(None, 96, 96, 64)	1664
conv2d_46 (Conv2D)	(None, 94, 94, 64)	36928
max_pooling2d_30 (MaxPooling)	(None, 47, 47, 64)	0
conv2d_47 (Conv2D)	(None, 45, 45, 64)	36928
max_pooling2d_31 (MaxPooling)	(None, 22, 22, 64)	0
flatten_15 (Flatten)	(None, 30976)	0
dense_30 (Dense)	(None, 128)	3965056
dense_31 (Dense)	(None, 11)	1419
Total params: 4,041,995		
Trainable params: 4,041,995		
Non-trainable params: 0		

Model: "sequential\_21"

Layer (type)	Output Shape	Param #
dense_44 (Dense)	(None, 700)	14700
batch_normalization_8 (Batch Normalization)	(None, 700)	2800
dense_45 (Dense)	(None, 400)	280400
batch_normalization_9 (Batch Normalization)	(None, 400)	1600
dropout_6 (Dropout)	(None, 400)	0
dense_46 (Dense)	(None, 300)	120300
batch_normalization_10 (Batch Normalization)	(None, 300)	1200
dropout_7 (Dropout)	(None, 300)	0
dense_47 (Dense)	(None, 100)	30100
batch_normalization_11 (Batch Normalization)	(None, 100)	400
dropout_8 (Dropout)	(None, 100)	0
dense_48 (Dense)	(None, 8)	808
Total params: 452,308		
Trainable params: 449,308		
Non-trainable params: 3,000		



<matplotlib.legend.Legend at 0x7f8d825583c8>



# PRUEBA FINAL




PROCESAMIENTO  
CON RANDOM FOREST



```
1 neigh.predict(Xtest)
array(['accomplish'], dtype=object)

1 neigh.predict_proba(Xtest)
array([[0.00109297, 0.00337066, 0.093046 , 0.02047726, 0.10234718,
        0.16551928, 0.02163382, 0.59251283]])
```




PROCESAMIENTO  
CON LA RED NEURONAL



```
1 a = np.argmax(model.predict(Xtest),axis=-1)
2 b = a[0]
3 print(elimanteDuplicated(y2)[b])

accomplish

1 model.predict(Xtest)
array([[7.3256786e-05, 4.1758353e-06, 1.9178513e-02, 3.3226101e-05,
        4.9589198e-05, 4.7792503e-07, 5.8723256e-02, 9.2193753e-01]],
      dtype=float32)
```



# CONCLUSIONES



El lenguaje de señas requiere de varias muestras por clase debido a que muchas de sus palabras tienen movimientos similares



El background da un mejor resultado del movimiento, debido a que las palabras a clasificar tienen un gesto muy similar entre ellas.



Los histogramas polares son un muy buen descriptor y reduce cada vídeo a un mínimo de valores.



Se requirió calcular el flujo óptico con la función canny de opencv para cada imagen a pasar y luego normalizar cada histograma además finalmente normalizar la suma de todos por vídeo, para obtener unos buenos resultados con el método de histogramas.



# REFERENCIAS



<https://machinelearningmastery.com/how-to-one-hot-encode-sequence-data-in-python/>



<https://hal.archives-ouvertes.fr/hal-01119640/document>



[https://www.researchgate.net/publication/336797133\\_Word-level\\_Deep\\_Sign\\_Language\\_Recognition\\_from\\_Video\\_A\\_New\\_Large-scale\\_Dataset\\_and\\_Methods\\_Comparison](https://www.researchgate.net/publication/336797133_Word-level_Deep_Sign_Language_Recognition_from_Video_A_New_Large-scale_Dataset_and_Methods_Comparison)



<https://likegeeks.com/es/procesar-de-imagenes-en-python/>